

Учебный пример D/3 NP

Layer	Model	Assumptions
① Conv 7x7 3→32	5/4 (maxPool)	• 1 MAC = 2 FLOPs
② Conv 5x5 32→64	5/4	• ReLU, Pooling numbers 0 FLOPs
③ Conv 3x3 64→128	5/8	• padding = k/2
④ Conv 1x1 128→256	5/8	• 3 channels
⑤ Conv 3x3 256→256	5/16	• by BatchNorm
⑥ Conv 1x1 256→512	5/16	
⑦ Linear 512→256, ReLU		
Linear 256→100		

уменьшение количества параметров
1. FLOPs ←

$FLOP_{(B)} = 2 \cdot B \cdot C_{in} \cdot C_{out} \cdot H_{out} \cdot W_{out} \cdot k^2$ - для сверток
 $FLOP_{(B, s)} = 2 \cdot B \cdot I \cdot O$ - для Linear и Global Avg Pool

C _{out}	C _{in}	H _{out}	W _{out}	k ²	
①	3	32	5/2	5/2	49
②	32	64	5/4	5/4	25
③	64	128	5/8	5/8	9
④	128	256	5/8	5/8	1
⑤	256	256	5/16	5/16	9
⑥	256	512	5/16	5/16	1

$$\begin{aligned}
 FLOP_{(B, s)} &= 2B \cdot 3 \cdot 32 \cdot \frac{5^2}{4} \cdot 49 & ① &= 49 \cdot 3 \cdot 16B5^2 = 2352B5^2 \\
 &= 2B \cdot 32 \cdot 64 \cdot \frac{5^2}{16} \cdot 25 & ② &= 256 \cdot 25B5^2 = 6400B5^2 \\
 &= 2B \cdot 64 \cdot 128 \cdot \frac{5^2}{64} \cdot 9 & ③ &= 256 \cdot 9B5^2 = 2304B5^2 \\
 &= 2B \cdot 128 \cdot 256 \cdot \frac{5^2}{64} \cdot 1 & ④ &= 1024B5^2 \\
 &= 2B \cdot 256 \cdot 256 \cdot \frac{5^2}{256} \cdot 9 & ⑤ &= 512 \cdot 9B5^2 = 4608B5^2 \\
 &= 2B \cdot 256 \cdot 512 \cdot \frac{5^2}{256} \cdot 1 & ⑥ &= 1024B5^2
 \end{aligned}$$

$$\begin{aligned}
 FLOP_{Linear}(B, s) &= 2B \cdot 512 \cdot 256 + 2B \cdot 256 \cdot 100 = 512B(512 + 100) = 512B \cdot 612 \\
 &= 313344B
 \end{aligned}$$

UTOT $FLOP_s(B, 9) = (2352 + 6400 + 2304 + 1024 + 4608 + 1024) B s^2 + 313344 B = B (177125^2 + 313344)$

2 Memory
наименьшая
↓ leca
наименьшая
↓ energy

Memory $(s, B) = M_{weights} + M_{calc}(B, s)$

Assumptions

- eval() model
- FP₃₂ (4 byte)
- inplace = true

$M_{weight} = (in \cdot out \cdot k^2) \cdot 4$

1) $M_{weight} = (3 \cdot 32 \cdot 49 + 32 \cdot 64 \cdot 25 + 64 \cdot 128 \cdot 9 + 128 \cdot 256 \cdot 1 + 256 \cdot 256 \cdot 9 + 256 \cdot 512 \cdot 1 + 512 \cdot 256 \cdot 100) \cdot 4 = (1,039,968) \cdot 4 \text{ byte} = 4,159,872$

2) $M_{calc}(B, s) =$

Input = $B \cdot 3 \cdot s \cdot s = 12 B s^2$

~~Conv~~ ① Outputs: (4 B C.H.W) ~~MaxPool~~

① - $32 B s^2$, MaxPool - $8 B s^2$, ② - $16 B s^2$, ③ - $8 B s^2$, ④ - $16 B s^2$,

⑤ - $4 B s^2$, ⑥ - $8 B s^2$, Linear - $2048 B$, $1024 B$, $400 B$

меньше модных действий
или 9×32

В памяти введем:

храним Input + Output

$12 B s^2 + 32 B s^2, 32 B s^2 + 8 B s^2, 8 B s^2 + 16 B s^2, \dots$, наименьшая

в начале $12 B s^2 + 32 B s^2 = 44 B s^2$

UTOT: $Memory(B, s) = 4,159,872 + 44 B s^2 \text{ bytes}$

3. Latency

Bytes Moved(B, S)
(calc)

← ^{нагрузка}
на процессор

θ_0 - время запуска

θ_{BW} - пропускная способность

θ_{FLOPS} - время на операцию

$$= (2+32)BS^2 + (32+8)BS^2 + (8+16)BS^2 + (16+8)BS^2 + (8+16)BS^2 + (16+4)BS^2 + (4+8)BS^2$$

(используем последние члены) =

ВСЕ ЧИСЛА ИЗ ПРЕДЫДУЩЕГО ЗАДАНИЯ

$$= 188 S^2$$

← ^{нагрузка}
на процессор

$$\text{BytesMoved}(B, S) = BM_{\text{memory}} + BM_{\text{calc}} = 4159872 + 188BS^2$$

$$\text{Latency}(B, S, \theta) = \theta_0 + \max \left(\underbrace{\frac{\text{BytesMoved}(B, S)}{\theta_{BW}}}_{\text{загрузка}}, \underbrace{\frac{\text{FLOPS}(B, S)}{\theta_{FLOPS}}}_{\text{время на операцию}} \right)$$

УТОГ: $\text{Latency}(B, S, \theta) = \theta_0 + \max \left(\frac{4159872 + 188BS^2}{\theta_{BW}}, \frac{17712S^2 + 313344}{\theta_{FLOPS}} \right)$

4. Energy

P_{idle} - мощность GPU

e_{byte} - энергия на I/O опер.

e_{flop} - энергия на 1 FLOP

$$\text{Energy}(B, S, \theta) = E_{\text{idle}} + E_{\text{memory}} + E_{\text{compute}}$$

$$P_{\text{idle}} \cdot \text{Latency}(B, S, \theta)$$

$$e_{\text{byte}} \cdot \text{BytesMoved}(B, S)$$

$$E_{\text{compute}} = e_{\text{flop}} \cdot \text{FLOPS}(B, S)$$

УТОГ: $\text{Energy}(B, S, \theta) = P_{\text{idle}} \cdot \text{Latency}(B, S, \theta) + e_{\text{byte}} \cdot (4159872 + 188BS^2) + e_{\text{flop}} \cdot (17712S^2 + 313344)$

$(P_{\text{idle}}, e_{\text{byte}}, e_{\text{flop}})$