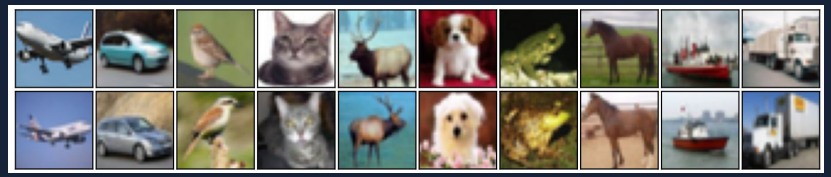
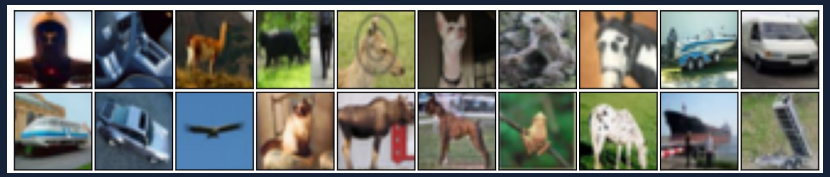
Разбор статьи

Deep Learning on a Data Diet

Доклад подготовил: Чебыкин Артём



Самые простые примеры



Самые сложные примеры

Зачем вообще искать важные примеры

КОНТЕКСТ

- Модели и датасеты растут, обучение требует всё больше вычислений
- Ресурсы ограничены
- Важные примеры нужны для online обучения
- Теоретически интересно, как отдельные примеры влияют на обучение целой модели

ВОПРОСЫ СТАТЬИ

Сколько обучающих данных лишние?

Какие примеры важны для обобщения?

Как найти их рано, не обучая модель до конца?

Что было до этой статьи

Подход	Идея	Ограничение
Coresets	Подмножество, для которого гарантируется близкая ошибка обучения на всех данных	Гарантии консервативны, слабы на практике
Forgetting (Toneva et al., 2018)	Считает, сколько раз пример забывается: из верно классифицированного становится ошибочным	Нужна статистика по траектории, оценку берут в середине или в конце обучения
Selection via proxy (Coleman et al., 2019)	Маленькая прокси-сеть отбирает данные для большой модели	Отбор после ≥ 50 эпох обучения прокси лучше случайного, но хуже, чем после полного обучения; меньшие сроки не изучались
AUM (Pleiss et al., 2020)	Запас (margin) по ходу обучения выявляет неверно размеченные примеры	Использует всю траекторию; цель - поиск шума, а не ранжирование важности
VoG, **prediction depth**	Сложность примера: дисперсия градиентов по чекпоинтам; слой, с которого kNN верно классифицирует пример	Нужны чекпоинты или обученная сеть

Что нового в статье: смотреть на примеры в самом начале обучения и не ждать, пока сеть обучится до конца

Идея статьи в двух словах

Простая оценка, усреднённая по нескольким запускам, находит важные примеры уже в первые эпохи обучения

Две оценки

GraNd и EL2N: два способа оценить, насколько пример важен

Прунинг данных

CIFAR-10: прунинг 50% данных без потери точности CIFAR-100 - 25% данных при потере примерно 1% точности

GraNd: насколько пример “толкает” сеть

- Для каждого примера смотрим, насколько сильно он двигает веса сети. Это размер его градиента
- Маленький градиент: влияние примера на остальные ограничено. Большой: пример может влиять сильно
- Чтобы не зависеть от случайной инициализации, усредняем по нескольким обучениям
- Это оценка сверху: большие градиенты иногда гасят друг друга



EL2N: насколько сеть ошибается на примере

- Берём предсказание сети для примера и сравниваем с правильным ответом
- Уверенно и верно: оценка около нуля. Уверенно и неверно: оценка высокая
- Считать просто: нужны только предсказания сети и метки, градиенты не нужны
- В статье показано, что EL2N хорошо заменяет GraNd уже через несколько эпох
- Оценка зависит от меток: варианты без меток заметно не лучше случайного отбора

ИЛЛЮСТРАЦИЯ: НА КАРТИНКЕ КОШКА

Лёгкий пример

Сеть на 90 % уверена, что это кошка

Оценка: низкая

Сложный пример

Сеть на 70 % уверена, что это собака

Оценка: высокая

Как всё это считается

1

Обучить 10 сетей

Разные сиды инициализации, только ранние эпохи (10-20)

2

Посчитать EL2N

Для каждого обучающего примера на выбранной эпохе

3

Усреднить

По 10 запускам: одна оценка на каждый пример

4

Отсортировать

Примеры по возрастанию оценки

5

Оставить только часть данных

Например, 50 % примеров с наибольшей оценкой

6

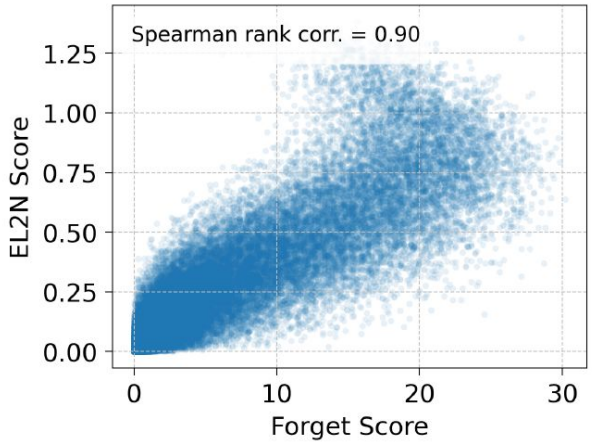
Обучить заново

Новая сеть с другими сидами - точность на тесте сравнивают с полной выборкой и случайным подмножеством

Сравнение EL2N и forgetting-оценок

	Forgetting	EL2N
Считает	Число переходов “верно → неверно” для примера в мини-батче	Ошибку предсказания сети на ранней эпохе
Данные	Вся траектория обучения	Локальная информация на одной ранней эпохе
Готово	В середине или в конце обучения	Через несколько эпох (10-20)
Ранние эпохи	По Toneva et al. ранние и поздние оценки согласуются лишь после примерно 25 эпох	Уже на эпохе 20 сопоставим с forgetting на эпохе 200

Итог: EL2N и forgetting дают самые близкие результаты и самую высокую ранговую корреляцию среди трёх сравнённых в статье оценок



ResNet18 + CIFAR-10

Как авторы проверяли идею

Параметры в числах

Параметр	Значение
Запусков для усреднения оценок	10
Запусков на каждую точку результатов	4
Длина обучения	200 эпох
Скорость обучения	0.1 - уменьшается в 5 раз на эпохах 60, 120, 160
Weight decay	0.0005

Данные

CIFAR-10, CIFAR-100 и CINIC-10
Часть работы только на CIFAR-10

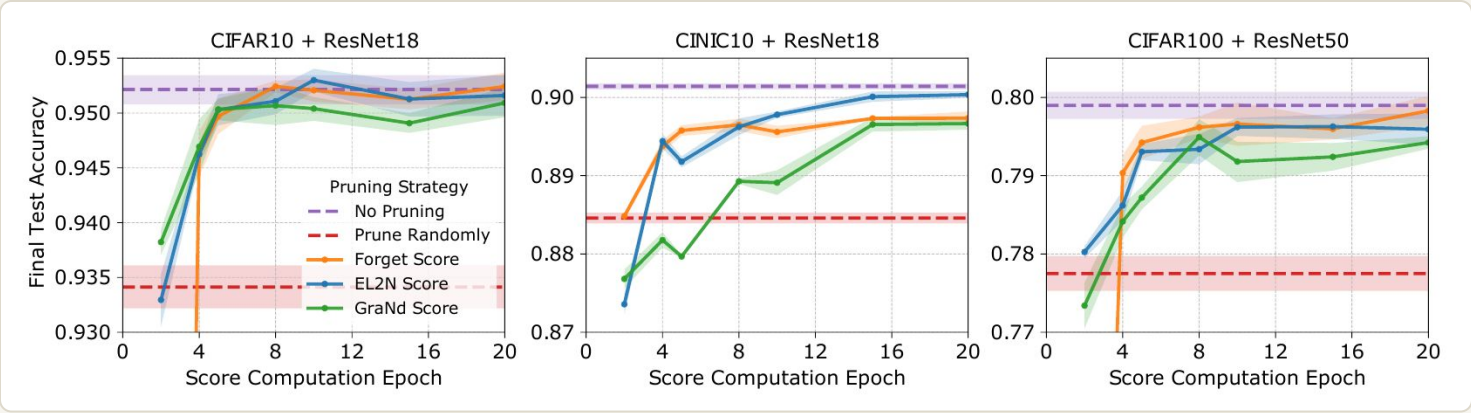
Модели

ResNet18 (CIFAR-10, CINIC-10) и ResNet50 (CIFAR-100)
Версия ResNet для маленьких картинок - первая свёртка 3×3, без max-pool

Обучение

- SGD
- Аугментация - случайные сдвиги и отражения
- Число шагов и расписание одинаковы для всех долей данных

Насколько рано можно считать оценки



Что показано

Подмножество фиксированного размера (50%, 60%, 75% данных) с наибольшими оценками, взятыми на разных эпохах

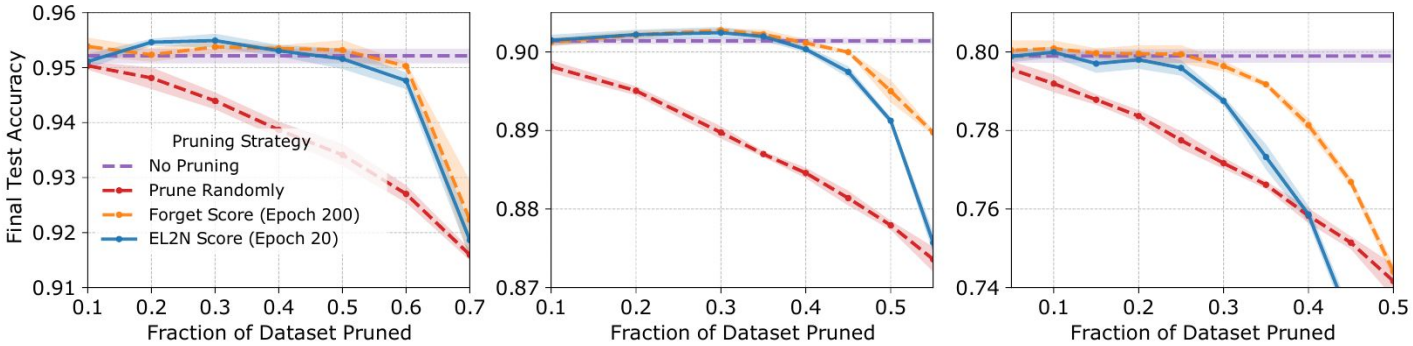
Быстрый выход на плато

На CIFAR-10 примерно с эпохи 5 точность близка к полной выборке и выше случайного отбора

Самый ранний срез слабее

На эпохе 2 EL2N и GraNd около уровня случайного отбора, forgetting ещё хуже GraNd на CINIC-10 заметно слабее EL2N

Прунинг: сколько данных можно убрать



Что показано

Отбрасываем самые лёгкие примеры: EL2N (эпоха 20) против forgetting (эпоха 200); базовые линии - вся выборка и случайный отбор

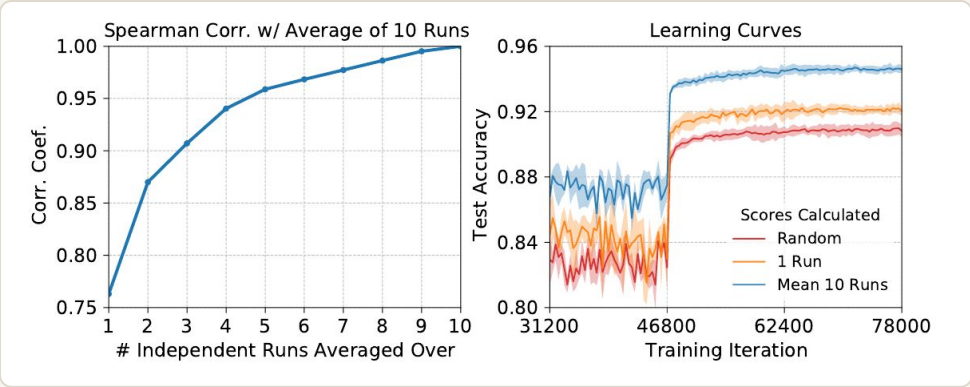
Умеренный прунинг без потерь

CIFAR-10: до 50% данных без потери точности; CIFAR-100: около 25% при потере примерно 1%

Резкое падение

При экстремальном прунинге точность резко падает; авторы предполагают, что пропадает покрытие данных

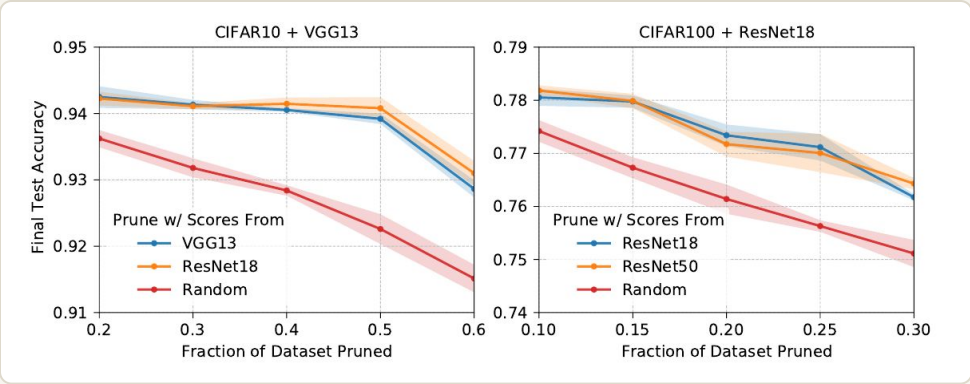
Почему нужно усреднять по запускам



EL2N, эпоха 10, ResNet18 + CIFAR-10

- Оценка по одному запуску даёт худшее подмножество, чем среднее по 10
- Корреляция с оценкой по 10 запускам растёт с числом усредняемых запусков
- Достаточно 10-20 запусков, дальше выгода незначительна
- Авторы предполагают, что усреднение убирает зависимость от конкретных весов

Оценки - скорее свойство датасета, чем сети



Оценки одной архитектуры подходят для другой: результат практически не отличается

ResNet18 и ResNet50 на CIFAR-10 дают сходные кривые прунинга

Оценки можно переиспользовать для новых сетей

Какие примеры получают высокие оценки

Наименьшие EL2N: два примера на класс



Наибольшие EL2N: два примера на класс



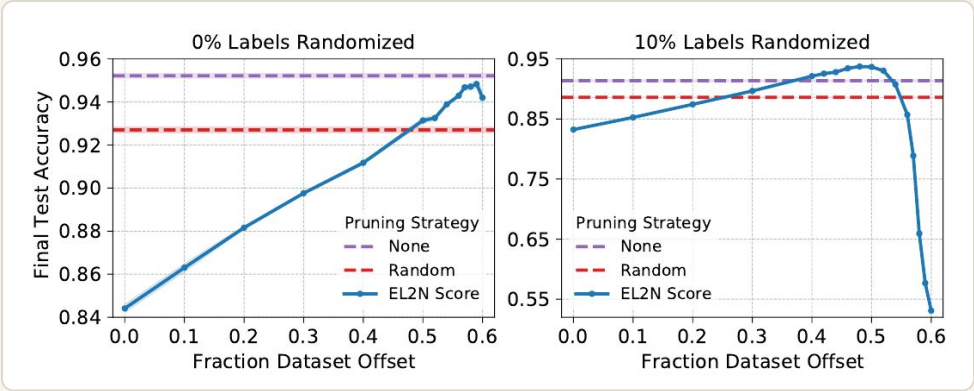
ResNet18, CIFAR-10, EL2N на эпохе 10.
Классы слева направо: airplane, automobile, bird, cat, deer, dog, frog, horse, ship, truck

Низкие оценки: типичные чёткие изображения в характерном ракурсе

Высокие оценки: размытые, необычные ракурсы, неожиданный фон, артефакты

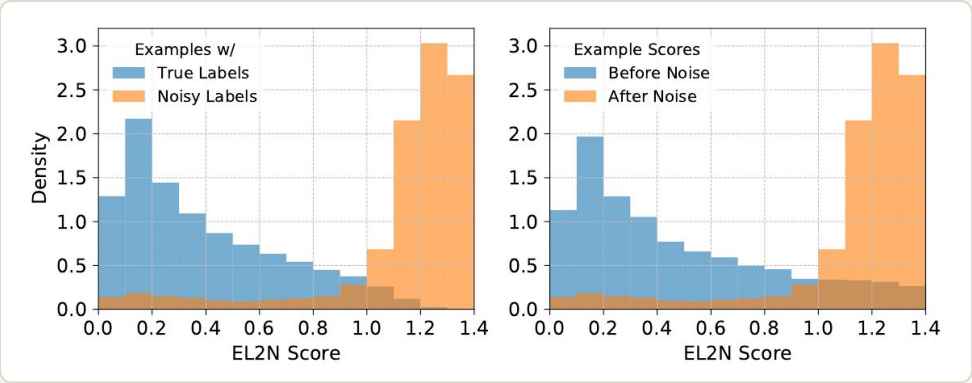
Присутствуют выбросы класса и примеры с ошибочной меткой

Самые сложные примеры не всегда полезны



- Окно из 40 % примеров сдвигается к более высоким оценкам
- Точность растёт, пока в окно не попадают самые высокие оценки; оптимум исключает примерно 500 из них
- При 10 % испорченных меток исключать нужно больше примеров

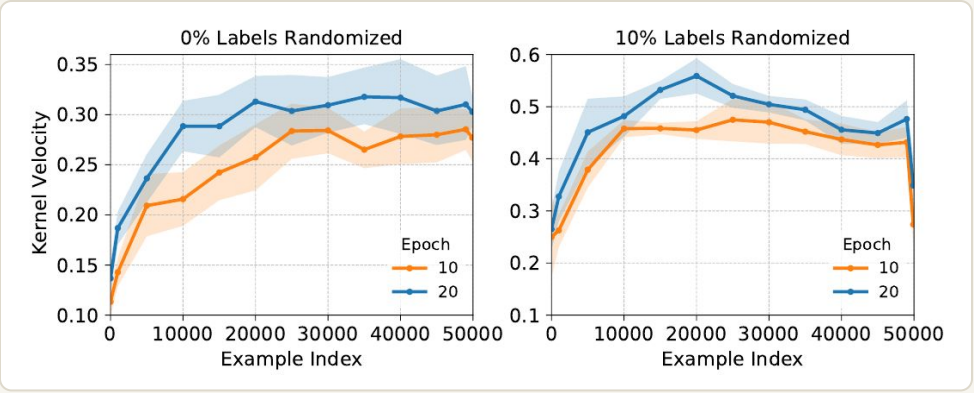
EL2N находит испорченные метки



Слева: распределение EL2N для примеров с верными и испорченными метками.
Справа: оценки испорченных примеров до и после порчи

- Эксперимент: у 10 % примеров CIFAR-10 метки перемешаны между собой
- У испорченных примеров EL2N в основном высокий, у остальных преимущественно низкий
- После порчи метки оценка того же примера растёт
- Подход дополняет AUM: их можно использовать вместе

Высокие оценки: быстрое изменение признаков



Скорость ядра для блоков из 100 примеров, отсортированных по EL2N (эпохи 10 и 20). Слева чистые метки, справа 10 % шума

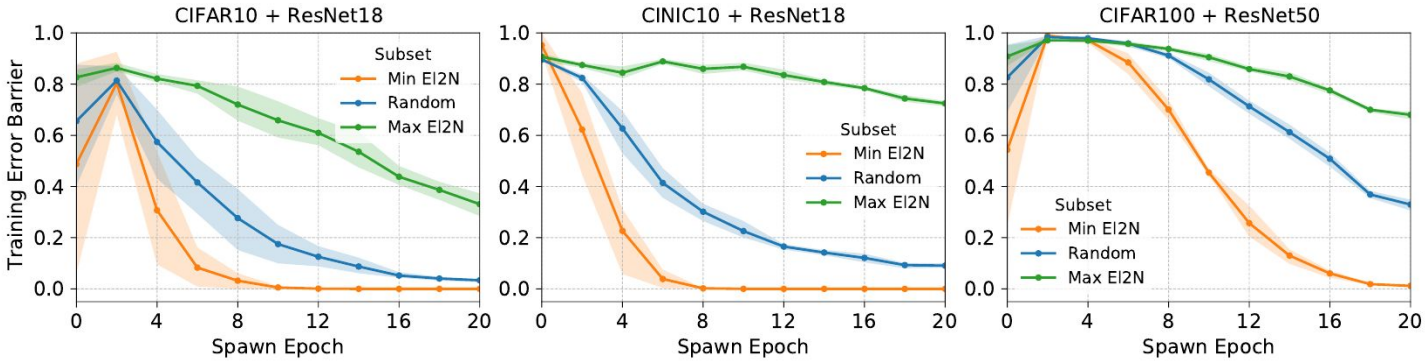
Скорость ядра - это то, насколько сильно оно изменилось за одну эпоху

Ядро NTK (матрица попарного сходства градиентов примеров) быстро меняется в начале обучения, потом успокаивается

Чем выше EL2N блока примеров, тем выше скорость ядра

При шуме скорость падает и у самых высоких оценок: возможно примеры слишком сложны, нетипичны или сожержат шум

Графики потерь на простых и сложных примерах



Что измеряют

От родителя на эпохе ветвления запускают двух потомков с разными минибатчами; смотрят барьер ошибки на линии между их весами

Низкий EL2N

Барьер быстро падает почти до нуля: график плоский

Высокий EL2N

Барьер остаётся высоким дольше: график неровный, что согласуется с идеей о том, что обучаются в основном сложные примеры

Ограничения и возможные проверки

Ограничения

- Теоретическое обоснование оценки неточное
- EL2N зависит от меток и требует около 10 обучений
- Резкое падение точности при сильном прунинге
- Метод с окном требует валидационной выборки
- Только классификация изображений (CIFAR-10, CIFAR-100, CINIC-10)
- Корреляции с memorization value не видно

Что можно проверить

- Стоимость оценок: 10 запусков × 20 эпох = 200 эпох, как одно полное обучение - существует выгода есть при повторном использовании оценок
- Другие домены и масштабы (текст, ImageNet): в статье не изучались
- Совместное использование с AUM и связь с VoG - направления, которые называют сами авторы
- Влияние прунинга на отдельные классы и группы: в основных экспериментах оценивается только общая итоговая точность
- Теоретическое объяснение, почему ранняя оценка работает

Что можно вынести из статьи

1. Ранние оценки EL2N, усреднённые по 10 запускам, находят важные примеры без обучения до конца
2. CIFAR-10: удаление 50% данных без потери точности; CIFAR-100 - 25% при потере 1% точности
3. Оценки примеров - свойство датасета: сохраняются при изменении архитектур и гиперпараметров
4. Самые высокие оценки: сложные примеры и шум, их не всегда стоит оставлять
5. Примеры с высоким EL2N сильнее всего двигают ядро NTK - учатся в основном они

Основа доклада

Deep Learning on a Data Diet: Finding Important Examples Early in Training

M. Paul, S. Ganguli, G. K. Dziugaite. NeurIPS 2021

Упомянутые работы: Toneva et al. (forgetting), Coleman et al. (selection via proxy), Pleiss et al. (AUM), Feldman и Zhang (memorization)